Knowledge Engineering und Lernen in Spielen

Einführung in Human Learning

Vortrag von Stefan Steger

Übersicht

- Einleitung
- Perception and Memory
- Problemsolving
- Empirical Studies of Learning
- Human learning

 Machine Learning
- Conclusion
- Reference list

Einleitung

Künstliche Intelligenz + Psychologie der Wahrnehmung = Erkenntnisforschung (Cognitive Sciense)

Neues interdisziplinäres Forschungsfeld (in den 50ern gegründet)

Wieso Spiele?

- Wohldefiniert
- Komplex
- Spielstärke ist messbar (ELO in Schach)
- Einige Spiele sind gut erforscht (Schach, Gomoku, ...)

Memory – Basic skill effects

Experiment: Recall-Task

- Eine Spielposition wird 5 sec lang einer Testperson gezeigt
- Danach soll sie die Stellung reproduzieren

Ergebnis:

- Schachmeister haben 100% Übereinstimmung
- Schlechtere Spieler kaum mehr als 50%
- Anfänger circa 3 Figuren

Interpretation:

- Experten rufen Wissen schneller ab als Anfänger
- Auch bei anderen Spielen (Go, Othello, Skat…)

Bei zufälligen Spielstellungen sind Experten nicht viel besser als Anfänger!

Memory - Chunks

- Chunks: Wahrnehmungsmuster im Langzeitgedächtnis
- Annahme von Chase & Simon: Schachmeister sind besser aufgrund einer großen Anzahl von Chunks
- Hinweise für die Annahme:
 - Trotz gleicher Gedächtniskapazität sind Schachmeister besser
 - Erfahrene Spieler merken sich größere Muster
 - Erfahrene Spieler kopieren größere Muster (copy-task)

Memory - High-level knowledge

- Schachspieler nutzen neben Chunks auch Expertenwissen
- Auch bei Go wird Expertenwissen angewandt um eine Stellung einschätzen zu können
- Die Indizierung der Chunks scheint wichtig zu sein

Perception – Eye Movement

- Einige Wahrnehmungsmechanismen von Experten wurden entschlüsselt
- Es wird angenommen, dass sich bei Experten mit zunehmenden Fähigkeiten auch die Wahrnehmung steigert

Eye-movements

- Experten sehen anders:
 - fixieren schneller (250ms gegenüber 300ms)
 - weniger Abweichung
 - überblicken mehr Felder
 - fokussieren die wichtigen Felder
 - fixieren eher Ränder von Feldern (deutet auf Chunks hin)

Perception – low-level features

- Meister sind schneller im
 - erkennen von Schach
 - zählen der Läufer und Pferde

- Chunking könnte dies Verhalten begünstigen, man braucht aber noch andere Theorien
 - Discrimination nets (z.B. in EPAM)
 - Gestalt principles (Nachbarschaft, Gleichheit, gute Weiterführung)

Perception – high-level features

- Schachmeister können sich eine Schachposition nach 2s gut merken
- Sie erkennen Schlüsselpositionen in 1s
- Deutet darauf hin, dass der Erkennungsprozess automatisch abläuft
- Wird durch die Chunking-Theorie gestützt

Chunking theory

- Die Chunking Theorie basiert auf EPAM
- Expertise ist möglich durch Erlernen (und das Abrufen) von großen Chunk-Datenbanken
- Chunks sind Knoten in einem discrimination net und dienen als Index
- Man braucht
 - 10.000 100.000 Chunks, um Fachwissen zu erwerben
 - Bis zu 300.000 Chunks, um Großmeister zu sein

Template theory

- Die Chunking Theorie hat 2 Nachteile
 - Überbewertet Zeit um Chunks zu lernen
 - Betrachtet kleine Chunks, vernachlässigt Expertenwissen
- Deshalb Template Theorie (erweitert Chunk Theorie)
 - Chunks entfalten sich zu komplexeren und größeren Mustern
 - die Slots für Informationen haben
 - diese Informationen k\u00f6nnen schnell abgelegt werden (250ms)

Problem Solving

Spieler sollen laut mitdenken, wird protokolliert

Ergebniss:

- Spielbaum höchstens 100 Koten stark
- Spielbäume von Schachmeistern nicht größer
- Aber expandieren wichtigere Zweige
- GM ~ 5,3; Fortgeschrittene ~4,8; Anfänger ~2,3
 Züge tief
- Spieler neigen dazu, Äste wiederholt zu besuchen (progressive deepening)

Problem solving — Theory

• Prinzipien:

- Analyse von Basiszügen ist unabhängig von anderen Basiszügen
- Erst Standardzüge, danach ungewöhnliche Züge
- Wenn Zugabfolge viel versprechende Ergebnisse liefert, wird weitergesucht, ansonsten wird ein anderer Basiszug gewählt
- Bevor gezogen wird, werden Alternativzüge getestet
- Basiszüge werden aufgegeben, wenn andere Züge entdeckt werden, die besser für Testperson oder Gegner sind

Wieso progressive deepening?

- Es werden neue Aspekte gefunden
- Der Zug hält nicht das, was er verspricht
- Analyse des Basiszuges ergibt andere Resultate als erwartet

Models without learning

Programme mit wenig Human Behavior

- NSS
 - Basiert auf Zielen wie Materialbalance und Zentrumskontrolle
 - 2 Zuggeneratoren, für Basiszüge und für auftretende Züge
 - Schlechte Performance, aber nur 100 Knoten
- MATER
 - Sucht Züge, bei denen der Gegner kaum Zugmöglichkeiten hat
 - Stark in Mattsituationen, ansonsten sehr schwach

Programme mit viel Human Behavior

- Pitrat's Program
 - Untersucht Stellung und schmiedet Pläne
 - 4 Ziele (Figurengewinn, Doppelattacke, Schach, Bauernentwicklung)
 - Wenn Plan zu keinem Ergebnis führt, wird Suche gestartet
 - Für Mattsuche gut, ansonsten schwach
- PARADISE
 - 200 Produktionsregeln, um Pläne zu schmieden
 - Findet taktische Kombinationen im Mittelspiel
 - Ist dort so gut wie ein Schachexperte

Models with learning

CHUMP

- Basiert auf CHREST und Chunking Theorie
- Erkennt Muster
- Hat Konflikt Management
- Es gibt keine Suchstrategie

SEARCH

- Berechnet Variablen (Tiefe der Züge, Züge pro Minute)
- In Abhängigkeit von der Anzahl der Chunks
- Suche wird durch Templates vereinfacht
 - Es werden schneller Informationen zum Langzeitgedächtnis hinzugefügt
 - Suche findet auch im Template-space statt
- SEARCH ist kein Schachprogramm, sondern ein Abstraktes Model

Empirical Studies – Short-range learning

 Recall-task von 1s bis 60s durchgefürt, um Chunking and Templates Theorie zu bestätigen

Ergebnis:

- logistische Wachstumsfunktion, die sowohl beim menschlichen, als auch beim simulierten Model gut passt
- Stärkere Spieler nehmen mehr Informationen auf
- Auch bei längeren Präsentationszeiten ziehen sie einen höheren Lerngewinn

Empirical Studies – Medium-range learning

Anfänger wurden 50h lang trainiert

Ergebnis:

- Ähnlich gut wie Schachmeister im Erkennen von Chunks
- Scannt aber Ecken, gibt Chunks eigene Namen (Eselsbrücke)
- Vernachlässigt Figuren in der Mitte
- Andere Chunks als Erfahrene Spieler

Empirical Studies – Long-range learning

- Testperson wurde nach 9 Jahren noch mal getestet (1600ELO – 2400ELO)
- Ergebnis
 - Recall-task perfekt gelöst
 - Weniger und größere Chunks
 - Zeit zwischen Chunks war kürzer
 - Deutet auf hierarchische Struktur von Chunks hin
 - Problem solving:
 - · Schneller, selektiver, kleinerer Suchbaum, aber gleiche Tiefe
- Bestätigt Chunking & Template theory
 - Steigerung der Fähigkeit beruht auf
 - · Unterschiede im chunking
 - Nicht so sehr auf Verbesserung der Suche

Human learning » Machine learning

- Beeinflussung des Maschine learning durch Human learning:
 - Selective search
 - Progressive deepening
 - Chunking & Template Theorie
- In verschiedenen Programmen implementiert
 - MATER
 - CHREST
 - CHUMP

Machine learning » Human learning

- Programme brauchen enorme Vorwärtssuchen, um auf ähnliche Selektion wie Menschen zu kommen
- Machine learning auf großen Datenbanken ergab eine Serie von Regelmäßigkeiten in Mittel- und Endspielen
- Dies erweitert das Verständnis für das Spiel
- Und erklärt, wieso Menschen einige Prinzipien gelernt haben, und andere nicht
- Man kann spezielle Hypothesen ableiten
 - Lernen Menschen genauso wir Maschienen?
 - Machen sie die gleichen Fehler?

Conclusion

- Aus Sicht des Machine learning sind Spiele nicht an sich interessant, sonder das Verstehen der Prinzipien des Lernens
- Psychologen hingegen interessieren sich vor allem für die Mechanismen der Wahrnehmung
- In den letzten Jahren wurde viel in dieser Richtung geforscht
- Der nächste große Schritt ist das Verbinden all dieser Theorien zu einer allgemeinen Theorie über das menschliche Spielen

Reference list

- Gobet, F. & Simon, H. A. Human learning in game playing
- Chase, W. G. & Simon, H. A. The mind's eye in chess

Ende

Danke für die Aufmerksamkeit

Noch Fragen?