Vorlesung Semantic Web



Vorlesung im Wintersemester 2012/2013 Dr. Heiko Paulheim Fachgebiet Knowledge Engineering



Was bisher geschah

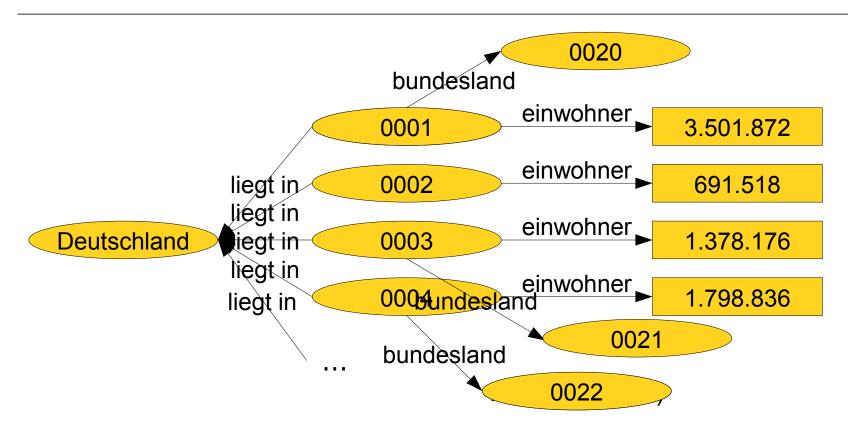


- Was wir bisher kennen gelernt haben:
 - RDF und RDF Schema als Sprachen
 - Linked Open Data
- Wie wir bisher auf Linked Open Data zugegriffen haben
 - mit Browsern
 - Graphen entlang hangelnd
- ...schauen wir uns das noch mal an!



Ein RDF-Beispielgraph





Aufgabe: in welchen Bundesländern liegen die fünf größten deutschen Städte?



Informationsbeschaffung auf Linked Open Data



- Aufgabe: in welchen Bundesländern liegen die fünf größten deutschen Städte?
- Probieren wir das aus...



Fazit

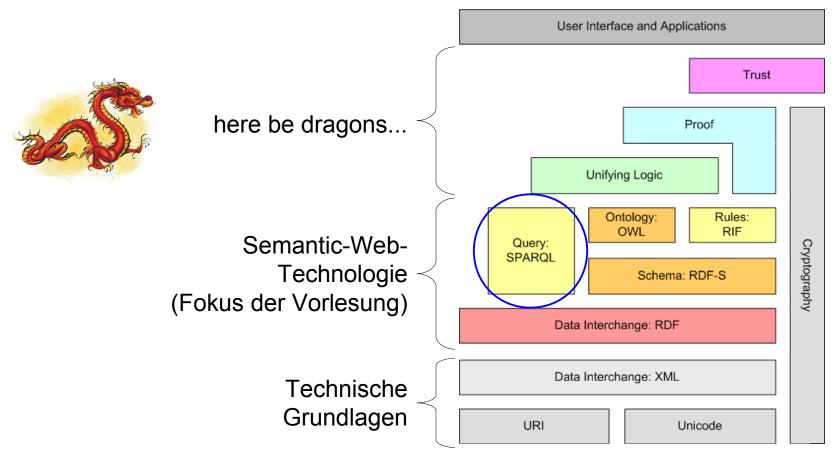


- So ist das sehr mühselig!
- Geht das nicht irgendwie einfacher?



Semantic Web - Aufbau



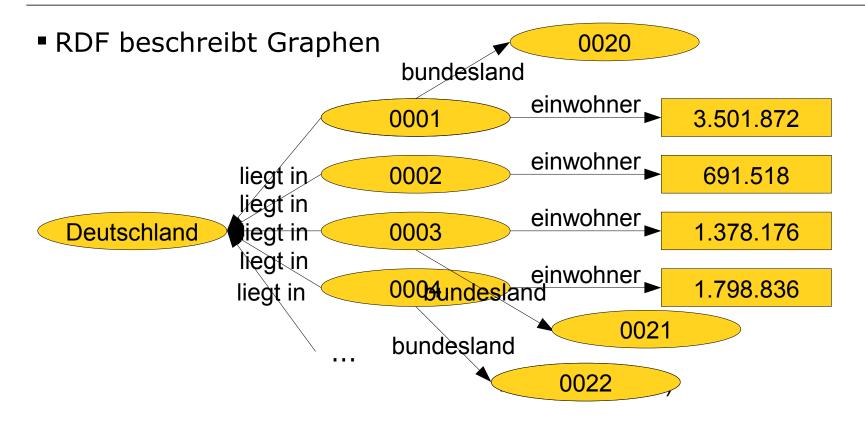


Berners-Lee (2009): Semantic Web and Linked Data http://www.w3.org/2009/Talks/0120-campus-party-tbl/



Was hätten wir denn gern?







Gesucht: eine Abfragesprache für das Semantic Web



Analog zu SQL für relationale Datenbanken:

SELECT WHERE

Name, Geburtsdatum FROM Kunden

Kundenummer = '00423789'

Kundennummer	Name	Geburtsdatum
00183283	Stefan Müller	23.08.1975
00423782	Julia Meyer	05.09.1982
00789534	Gertrud Schäfer	31.03.1953
00423789	Herbert Scholz	02.04.1960
	•••	



Gesucht: eine Abfragesprache für das Semantic Web



- SPARQL: "SPARQL Query Language for RDF"
 - ein rekursives Akronoym



- Standardisiert vom W3C (2008)
- Abfragen auf RDF-Graphen
- Übung 1, Aufgabe 3:
 - Merke: XPath und RDF/XML ist eine ganz schlechte Idee!
 - Etwas besseres lernen wir in Kürze kennen...



Hello SPARQL!



Beispiel:

```
SELECT ?child
WHERE { :Stefan :vaterVon(?child)}
```

Ausdrücke mit ? kennzeichnen Variablen

:Stefan :vaterVon :Julia



SPARQL: Grundkonzepte



Grundstruktur:

```
SELECT <Variablenliste>
WHERE { <Muster> }
```

- Variablen mit ?
- Namensräume: wie in RDF/N3:

```
PREFIX foaf: <http://xmlns.com/foaf/0.1/>
SELECT ?person ?name
WHERE { ?person foaf:name ?name }
```



SPARQL: Grundkonzepte



- Der WHERE-Teil ist ähnlich wie N3-Notation
 - mit Variablen

```
{?p foaf:name ?n }
```

- {?p foaf:name ?n; foaf:homepage ?hp }
- {?p foaf:knows ?p1, ?p2 }



SPARQL: Pattern Matching auf RDF-Graphen



WHERE-Teil der Abfrage: ein RDF-Graph mit Va

über gemeinsame Variablen wird ein komplexes Muster definiert

- Ergebnis:
 - ?person1 = :Peter, ?person2 = :Julia

```
:Peter :kennt :Julia
```



SPARQL: Matching auf Graphen



- Eine Person, die eine Tochter und einen Sohn hat
 { ?p :hatTochter ?t ; :hatSohn ?s . }
- Eine Person, die zwei Personen kennt, die sich untereinander kennen

```
{ ?p :kennt ?p1 , ?p2 . ?p1 :kennt ?p2 . }
```

• Eine Person, die zwei Kinder hat
{ ?p :hatkind ?k1, ?k2 . }

Achtung: zwei Variablen müssen nicht automatisch an verschiedene Ressourcen gebunden werden!



SPARQL: Blank Nodes



WHERE-Teil der Abfrage: ein RDF-Graph mit Variablen

- Ergebnis:
 - ?person1 = :Peter, ?person2 = :Julia; ?anderePerson = _:x1
- Blank Node IDs sind nur eindeutig innerhalb des Result Sets!

```
:Peter :kennt :Julia
```



SPARQL: Matching von Literalen



Strings

```
{ ?country :name "Deutschland" . }
```

Vorsicht bei Sprachangaben:

```
{ ?country :name "Deutschland"@de . }
```

→ Die Strings "Deutschland" und "Deutschland"@de sind verschieden!

Zahlen:

```
{ ?person :alter "42"^^xsd:int .}

oder kürzer:
{ ?person :alter 42 . }
```



SPARQL: Filter



Zur weiteren Eingrenzung von Ergebnissen

```
{?person :age ?age . FILTER(?age < 42) }
```

Vergleichsoperatoren:

```
= != < > <= >=
```

Logische Verknüpfungen:

```
&& || !
```



SPARQL:Filter



Personen, die jüngere Geschwister haben

```
{ ?p1 :geschwisterVon ?p2 .
   ?p1 :alter ?a1 .
   ?p2 :alter ?a2 .
   FILTER(?a2 < ?a1)}</pre>
```

Personen, die sowohl jüngere und ältere Geschwister haben

```
{ ?p1 :geschwisterVon ?p2,p3 .
   ?p1 :alter ?a1 .
   ?p2 :alter ?a2 .
   ?p3 :alter ?a3 .
   FILTER(?a2 < ?a1 && ?a3 > ?a1)}
```



SPARQL: Filter



Zweiter Versuch: Eine Person, die zwei Kinder hat

```
{ ?p :hatKind ?k1, ?k2 . FILTER( ?k1 != ?k2) }
```

- Schon mal besser als der erste Versuch
 - → Variablen werden jetzt unterschiedlich gebunden
- Aber: es gilt immer noch die Non-Unique Naming Assumption
 - → Aus
 - :Peter :hatKind :Julia .
 - :Peter :hatKind :Stefan .

folgt immer noch nicht, dass Peter zwei Kinder hat!

- Darüber hinaus gilt die Open World Assumption
 - → Peter könnte also auch noch mehr Kinder haben



Filter auf Strings



- Suche in Strings: Reguläre Ausdrücke
- Personen, die "Heinz" heißen

```
{?person :name ?n . FILTER(regex(?n,"^Heinz$")) }
{?person :name ?n . FILTER(regex(?n,"Heinz")) }
```

- → die zweite Variante findet z.B. auch "Karl-Heinz"
- str: URIs und Literale als Strings
- ermöglicht u.a. Suche über String-Literale in allen Sprachen

```
{?country : name ?n . FILTER(str(?n) = "Tyskland") }
```

→ wir lernen: Deutschland heißt auch auf norwegisch "Tyskland".



Weitere eingebaute Funktionen



- Typ einer Ressource abfragen:
 - isURI
 - isBLANK
 - isLITERAL
- Datentyp und Sprache eines Literals abfragen:
 - DATATYPE (?v)
 - LANG(?v)
- Sprache von zwei Literalen vergleichen:
 - langMATCHES(?v1,?v2)
 - Achtung: sei ?v1 = "Januar"@DE, ?v2 = "Jänner"@DE-at
 LANG(?v1) = LANG(?v2) → false
 langMATCHES(?v1,?v2) → true



Verknüpfung von Teilmustern



Finde die private oder dienstliche Telefonnummer

```
{ ?p :privatePhone ?nr }
UNION { ?p :workPhone ?nr }
```

UNION erzeugt eine Vereinigungsmenge

```
?p = :peter, ?nr = 123;
?p = :hans, ?nr = 234;
?p = :hans, ?nr = 345;
...
```

Das passiert, wenn Hans sowohl eine private als auch eine dienstliche Nummer hat



Optionale Teilmuster



 Finde die Telefonnummer einer Person und, falls vorhanden, auch die Faxnummer

```
{ ?p :phone ?tel }
OPTIONAL { ?p :fax ?fax }
```

OPTIONAL erzeugt auch ungebundene Variablen

```
?p = :peter, ?tel = 123, ?fax = 456;
?p = :hans, ?tel = 234, ?fax = ;
?p = :jutta, ?nr = 978; ?fax = 349;
...
```

Ungebundene Variable:
Hans hat kein Fax
(soweit wir das wissen)



Ungebundene Variablen



- Variablen können auch ungebunden bleiben
- Mit BOUND(?v) kann man das abfragen
- Alle Personen, die Telefon oder Fax haben (oder beides):

```
OPTIONAL {?p :phone ?tel . }
OPTIONAL {?p :fax ?fax . }
FILTER ( BOUND(?tel) || BOUND(?fax) )
```



Negation



- Häufige Frage mit Bezug auf SPARQL
- Wie geht so etwas:
 - "Finde alle Personen, die keine Geschwister haben."
- Das hat man in SPARQL bewusst nicht direkt vorgesehen
- Warum?
- Open World Assumption
 - wir können das gar nicht wissen!
- Aus dem selben Grund gibt es (noch) kein COUNT



Negation – Hacking SPARQL



- Es gibt dennoch Möglichkeiten
 - im "Giftschrank" von SPARQL...
- Mit optional und bound
- Finde alle Personen ohne Geschwister:

```
OPTIONAL {?p :hasSibling ?s . }
FILTER ( !BOUND(?s) )
```

- Das funktioniert
- man sollte aber immer wissen, was man tut
 - und wie die Ergebnisse zu interpretieren sind!





Negation – Hacking SPARQL



- Wie funktioniert das?
- Ergebnisse vor FILTER:

```
OPTIONAL {?p :hasSibling ?s . }

?p = :peter, ?s = :julia
?p = :peter, ?s = :stephan
?p = :jan, ?s =
?p = :paul, ?s =
Ungebundene Variablen
```

Anwendung von FILTER

```
FILTER(!BOUND(?s))
```

```
?p = :jan, ?s = ?p = :paul, ?s =
```



Sortieren der Ergebnisse



■ Sortierung: ORDER BY ?name

■ Begrenzung: LIMIT 100

■ Untere Grenze: OFFSET 200

- Beispiel: die Personen 101-200, nach Namen sortiert
 - ORDER BY ?name LIMIT 100 OFFSET 100
- LIMIT/OFFSET ohne ORDER BY:
 - Ergebnisse nicht deterministisch
 - Es gibt keine default-Ordnung!



Ausfiltern von Duplikaten



- SELECT DISTINCT ?person
 WHERE { ?person :privatePhone ?nr }
 UNION { ?person :workPhone ?nr }
- Bedeutet: Es werden alle Ergebnisse mit identischer Wertebelegung der Variablen ausgefiltert
- Bedeutet nicht: die Personen, die durch die Werte von ?person identifiziert werden, sind tatsächlich verschieden!
- Warum?
 - Non-unique naming assumption



Custom Built-Ins



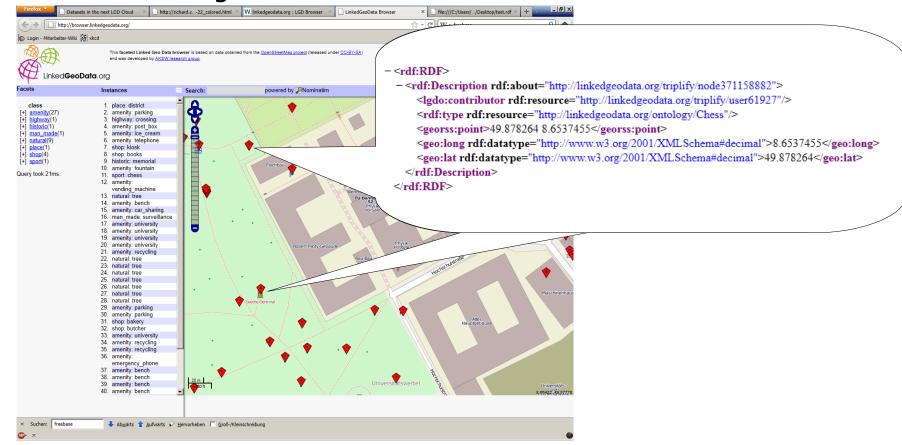
- Manche Anbieter von Endpoints erlauben zusätzliche Filter
- sog. Custom Built-Ins
- Beispiel Linked Geo Data



LinkedGeoData



hat auch ein eigenes User Interface:





Custom Built-Ins



- Abfrage nach Koordinaten
 - naiv:

```
WHERE { ?x geo:long ?long; geo:lat ?lat } FILTER (?long >8.653, ?long < 8.654, ?lat >49.878, ?lat < 49.879)
```

- Komplexere Anfragen
 - alle Cafés, die sich im Umkreis von 1km von einem bestimmten Punkt befinden



Custom Built-Ins



- Noch komplexere Anfragen
 - alle Cafés, die sich im Umkreis von 1km von einer Universität befinden



Weitere Abfragearten: ASK



- Bis jetzt haben wir nur SELECT kennen gelernt
- Mit ASK kann man Ja/Nein-Fragen stellen: Gibt es Personen mit Geschwistern?

```
ASK {?p :hasSibling ?s . }
```

- Die Antwort ist true oder false
 - wobei false heißt, dass keine passenden Daten gefunden wurden
 - darf man nicht falsch interpretieren (Open World Assumption)



Weitere Abfragearten: DESCRIBE



Alle Eigenschaften einer Ressource:

```
DESCRIBE <http://dbpedia.org/resource/Berlin>
```

Auch mit WHERE-Klausel

```
DESCRIBE ?city WHERE { :Hans :livesIn ?city . }
```

- Ermöglicht das Explorieren eines Datensets, dessen Struktur unbekannt ist
- Achtung: Nicht-normativ, Ergebnisse variieren je nach Implementierung!





Weitere Abfragearten: CONSTRUCT



Erzeugen eines neuen RDF-Graphen

- Das Ergebnis ist ein kompletter RDF-Graph
 - z.B. zur Weiterverarbeitung



SPARQL: Zusammenfassung



- Abfragesprache für RDF
- Pattern-Matching auf Graphen
- Mit SPARQL kann man nach Informationen suchen, nicht nur über Graphen wandern
- Abfrageergebnisse unterliegen der Semantik von RDF!
 - Open World Assumption
 - Non-unique naming assumption





Implementierung



- Interface SPARQLQuery
 - Hat eine Methode (query())
 - Vom W3C komplett spezifiziert
- Umsetzung:
 - als Web Service (WSDL)
 - als HTTP-Schnittstelle
- Eine solche Schnittstelle nennt man SPARQL Endpoint

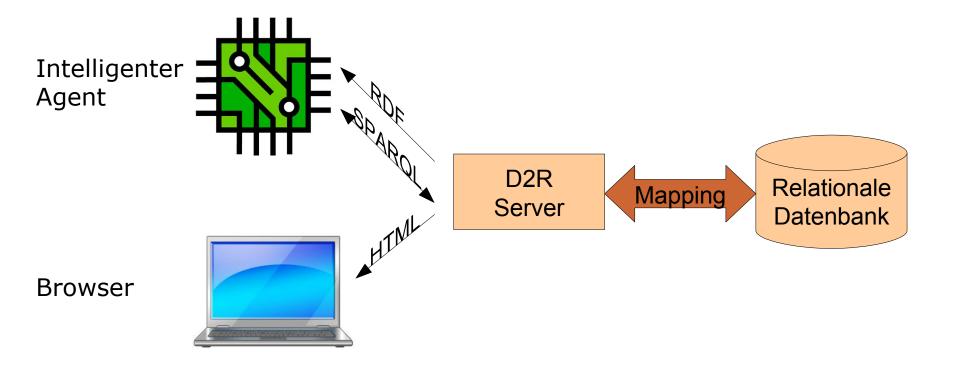




Implementierung



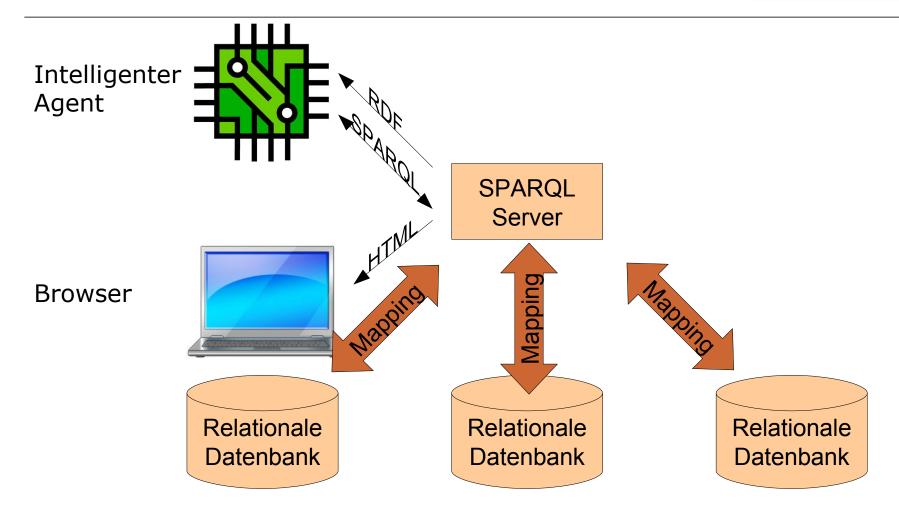
Viele Linked Open Data Server haben auch eine SPARQL Schnittstelle:





Anwendung: Datenintegration







Anwendung: Datenintegration



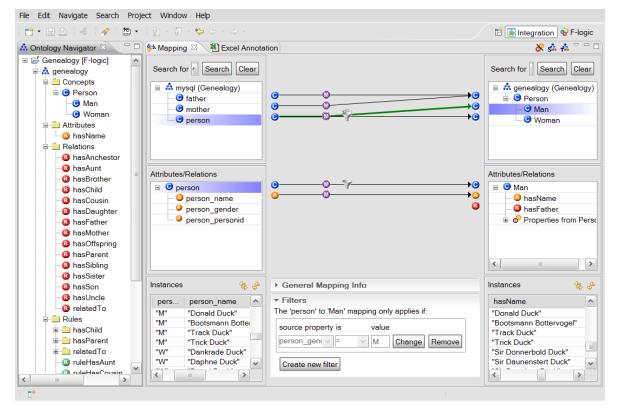
- Viele Datenbanken hinter einer SPARQL-Schnittstelle
- Nur noch ein RDF-Schema statt vieler DB-Schemata
- Zusammenhänge zwischen Datenbanken entdecken
- Funktioniert prinzipiell auch mit anderen Quellen
 - Strukturierte Dokumente (XML, CSV, ...)
 - Anwendungen, z.B. mit Web-Service-Schnittstellen



Anwendung: Datenintegration



Beispiel für ein kommerzielles Produkt: OntoStudio/OntoBroker



OntoPrise (2011): http://www.ontoprise.de/



Beispiel: Integration mehrerer Produktdatenbanken







CoRA Body Lollon Gesamtpreis (inkl. 2% Rabatt): 5,29€



Fig. 5. Subject with CoRA Fig. 6. Step-by-step comin front of a product shelf

position of a question

Fig. 7. Presentation of the answer

Janzen et al. (2010): Linkage of Heterogeneous Knowledge Resources within In-store Dialogue Interaction. In: International Semantic Web Conference 2010.





- Daten sind in relationalen DB gespeichert
 - werden mit SQL angesprochen
- Query-Interface: SPARQL
 - → Umsetzung von SPARQL auf SQL benötigt
 - je nach Implementierung unterschiedlich





Recap: Beispiel naiver Tripel-Store

Subjekt	Prädikat	Objekt
<http: foo.bar="" peter=""></http:>	<http: foo.bar="" vatervon=""></http:>	<http: foo.bar="" stefan=""></http:>
<http: foo.bar="" peter=""></http:>	<rdf:type></rdf:type>	<http: foo.bar="" person=""></http:>
">	<rdf:type></rdf:type>	<http: foo.bar="" person=""></http:>
<http: foo.bar="" peter=""></http:>	<http: foo.bar="" vatervon=""></http:>	<http: foo.bar="" julia=""></http:>
<http: foo.bar="" peter=""></http:>	<http: foo.bar="" kennt=""></http:>	_:genID01
_:genID01		http://foo.bar/Markus">





- Naiver Triple-Store
- SPARQL-Beispiel:

wird zu

```
SELECT t1.subjekt AS person, t1.objekt AS name, t2.objekt AS email

FROM triples AS t1, triples AS t2

WHERE t1.predicate = "foo:name"

AND t2.predicate = "foo:email"

AND t1.subjekt = t2.subjekt
```





Recap: Property Table

Subjekt	rdf:type	foo:vaterVon	foo:kennt
foo:Peter	foo:Person	foo:Stefan	NULL
foo:Peter	foo:Person	foo:Julia	NULL
foo:Stefan	foo:Person	NULL	_:genID01
_:genID01	foo:Person	foo:Markus	NULL





- Property Table
- SPARQL-Beispiel:

wird zu

```
SELECT subjekt AS person, name, email FROM properties
```





Recap: Vertikale Partitionierung

Subjekt	rdf:type
foo:Peter	foo:Person
_:genID01	foo:Person
•••	

Subjekt	foo:vaterVon
foo:Peter	foo:Stefan
foo:Peter	foo:Julia
_:genID01	foo:Markus
	•••

Subjekt	foo:kennt
foo:Stefan	_:genID01





- Vertikale Partitionierung
- SPARQL-Beispiel:

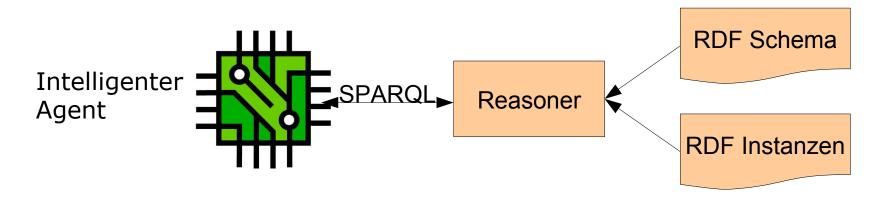
wird zu

```
SELECT t1.subjekt AS person, t1.name, t2.email
FROM name_table AS t1, email_table AS t2
WHERE t1.subjekt = t2.subjekt
```





- Reasoning mit RDF Schema haben wir schon kennen gelernt
- Viele Reasoner haben auch eine SPARQL-Schnittstelle







Beispiel-Ontologie

```
:Country a rdfs:Class .
:City a rdfs:Class .
:locatedIn a rdf:Property .
:capitalOf rdfs:subPropertyOf :locatedIn .
:capitalOf rdfs:domain :City .
:capitalOf rdfs:range :Country .
:Madrid :capitalOf :Spain .
:Barcelona :locatedIn :Spain .
:Spain rdfs:label "Spanien"@de .
```





- Finde die Hauptstadt von Spanien
 - z.B. so:

aber nicht so:

```
SELECT ?x WHERE { ?x :capitalOf ?y . ?x a :City . ?y rdfs:label "Spanien" . }
```





- Finde alle Städte in Spanien
 - z.B. so:

 Finde alle Städte in Spanien, die nicht Hauptstadt von Spanien sind

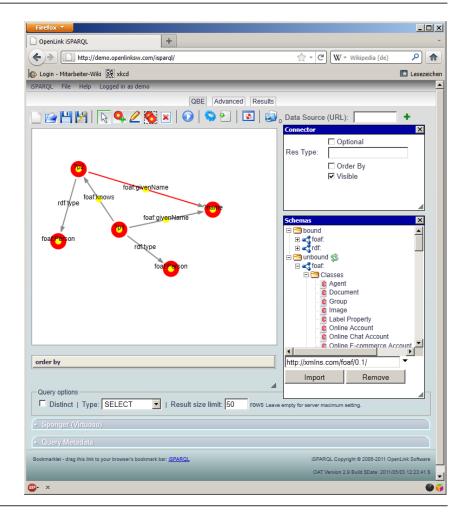
```
SELECT ?x WHERE { ?x :locatedIn :Spain . ?x a :City .}
    OPTIONAL { ?x :capitalOf ?y }
    FILTER (!BOUND(?y) || ?y != :Spain)
```



Visuelle Interfaces



- iSPARQL (2007)
- Query-by-Example
- Klassen und Relationen aus Schema per Drag and Drop
- Universität Zürich

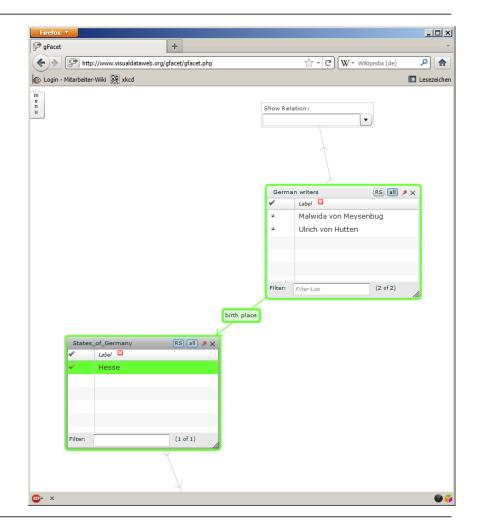




Visuelle Interfaces



- gFacet (2008)
- Exploration von Linked Open Data
- Einschränkungen
 - ausgehend von einem Konzept
 - nur die Kanten, die die Objekte tatsächlich besitzen
- Universität Duisburg-Essen





DERI Pipes

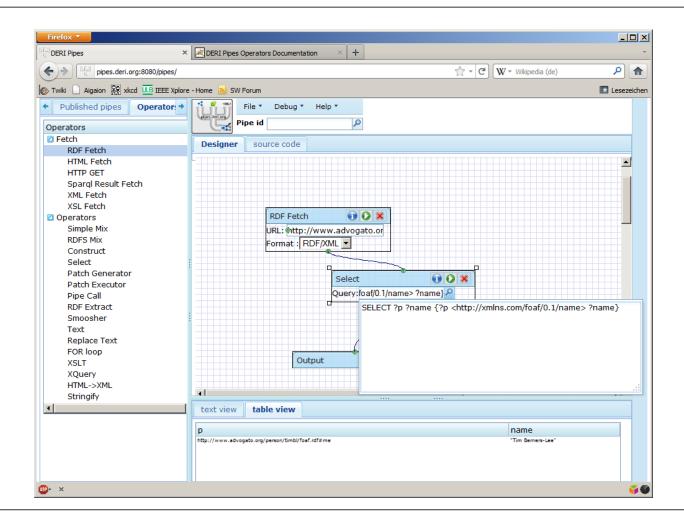


- Daten-Mashup
- Hat auch RDF-Bausteine:
 - RDF von Adresse holen
 - Daten in RDF umwandeln
 - Verschiedene RDF-Dokumente zusammenführen
 - SPARQL-Abfragen



DERI Pipes

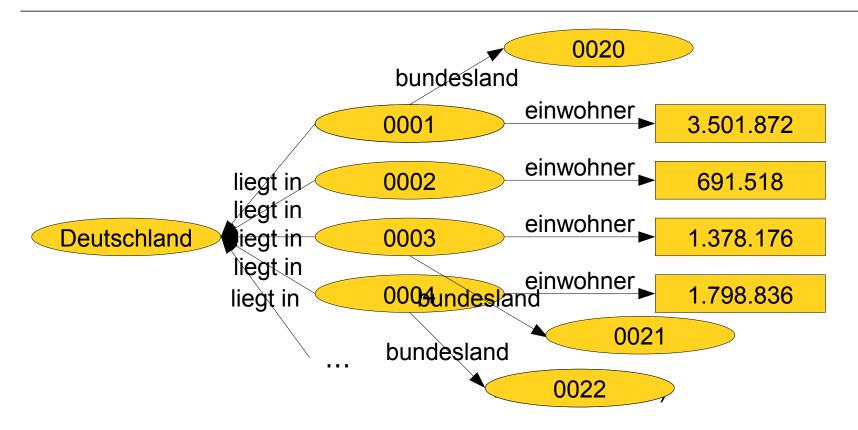






Zurück zum Ausgangsproblem







Zurück zum Ausgangsproblem



- Aufgabe: in welchen Bundesländern liegen die fünf größten deutschen Städte?
- Jetzt geht das ganz bequem:



Zusammenfassung

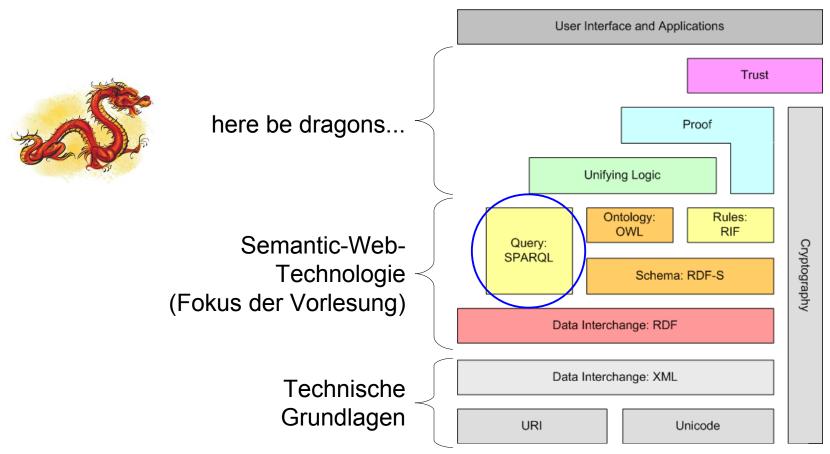


- SPARQL
 - eine Abfragesprache für RDF-Daten
 - Beschreibung von (Sub-)Graphen-Mustern
- Built-ins sind möglich
- Weiterverarbeitung im Triple Store
- Kombination mit Reasoning
- Abfrageergebnisse
 - unterliegen Open World Assumption
 - Verneinung daher nur auf Umwegen



Semantic Web - Aufbau





Berners-Lee (2009): Semantic Web and Linked Data http://www.w3.org/2009/Talks/0120-campus-party-tbl/



Vorlesung Semantic Web



Vorlesung im Wintersemester 2012/2013 Dr. Heiko Paulheim Fachgebiet Knowledge Engineering

